

LAPORAN KOMPREHENSIF CAPSTONE PROJECT
“Edu-Assist: Sistem Asisten Akademik Adaptif Berbasis RAG
dan Dashboard Monitoring Data”



Disusun Oleh:

- 1. Akhmad Ilhamzah (CDCC284D6Y1529)**
- 2. Aisyah Nur Rosalin (CDCC284D6X2527)**

CC26-PSU234

PROGRAM CODING CAMP
POWERED BY DBS FOUNDATION

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam era digital, pemanfaatan teknologi kecerdasan buatan di bidang pendidikan semakin berkembang, salah satunya melalui chatbot sebagai asisten belajar. Untuk meningkatkan relevansi jawaban chatbot, digunakan pendekatan RetrievalAugmented Generation (RAG) yang menggabungkan pengambilan informasi eksternal dengan model generatif berbasis bahasa alami. RAG merupakan metode yang menggabungkan kemampuan information retrieval dengan Large Language Model (LLM) untuk menghasilkan jawaban yang lebih relevan, kontekstual, dan informatif.

Sebagian besar sistem rekomendasi sederhana masih menggunakan pendekatan keyword matching yang hanya mengandalkan kecocokan literal antar kata. Pendekatan tersebut memiliki keterbatasan dalam memahami konteks dan hubungan semantik antar course. Akibatnya, rekomendasi yang dihasilkan sering kali kurang relevan terhadap kebutuhan pengguna.

Untuk mengatasi permasalahan tersebut, proyek ini mengembangkan sistem rekomendasi course berbasis content-based filtering menggunakan teknik embedding. Sistem memanfaatkan representasi teks berbasis TF-IDF dan cosine similarity untuk memahami hubungan antar course berdasarkan title, description, skills, dan level course.

Dengan memanfaatkan embedding, sistem dapat memahami hubungan konteks antar teks sehingga mampu memberikan rekomendasi yang lebih personal, relevan, dan adaptif dibanding metode pencarian sederhana. (Imanda, n.d.)

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah pada proyek ini adalah sebagai berikut:

1. Bagaimana distribusi course berdasarkan kategori dan tingkat kesulitan?
2. Bagaimana karakteristik teks pada course yang tersedia?
3. Seberapa besar kemiripan antar course berdasarkan representasi embedding?
4. Seberapa relevan recommendation system yang dihasilkan terhadap preferensi pengguna?
5. Apakah metode embedding lebih efektif dibandingkan pendekatan sederhana dalam menghasilkan rekomendasi?

1.3 Tujuan Proyek

Tujuan dari proyek ini adalah:

1. Menganalisis distribusi dan karakteristik dataset course.
2. Mengembangkan recommendation system berbasis content-based filtering.
3. Mengimplementasikan teknik embedding menggunakan TF-IDF.

4. Mengukur kemiripan antar course menggunakan cosine similarity.
5. Mengevaluasi efektivitas embedding dibanding pendekatan sederhana.

1.4 Manfaat Proyek

- Bagi Pengguna
 1. Membantu pengguna menemukan course yang relevan secara lebih cepat.
 2. Memberikan pengalaman belajar yang lebih personal.
 3. Mengurangi waktu pencarian course.
- Bagi Platform Pembelajaran
 1. Meningkatkan kualitas recommendation system.
 2. Meningkatkan engagement pengguna.
 3. Membantu distribusi course menjadi lebih optimal.

BAB II

TINJAUAN PUSTAKA

2.1 Recommendation system

Recommendation system merupakan sistem yang digunakan untuk memberikan rekomendasi item kepada pengguna berdasarkan preferensi atau kebutuhan tertentu. Sistem ini banyak digunakan pada platform digital seperti e-commerce, streaming platform, dan platform pembelajaran online. (Ricci et al., 2011)

Pada proyek ini digunakan pendekatan **content-based filtering**, yaitu metode recommendation system yang memberikan rekomendasi berdasarkan kemiripan karakteristik antar item. Sistem akan merekomendasikan course yang memiliki konteks atau informasi serupa dengan query pengguna.

Pendekatan ini dipilih karena dataset memiliki banyak fitur teks seperti title, description, dan skills yang dapat digunakan untuk mengukur kemiripan antar course.

2.2 TF-IDF (*Term Frequency–Inverse Document Frequency*)

TF-IDF merupakan metode representasi teks yang digunakan untuk mengubah data teks menjadi bentuk numerik berdasarkan bobot kata. (Salton & Buckley, 1988)

Metode ini bekerja dengan menghitung:

- Seberapa sering suatu kata muncul pada dokumen (Term Frequency),
- Seberapa penting kata tersebut dibanding dokumen lain (Inverse Document Frequency).

Rumus TF-IDF:

$$\text{TFIDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t)} \right)$$

Keterangan:

- $\text{TF}(t, d)$: frekuensi kata pada dokumen
- $\text{DF}(t)$: jumlah dokumen yang mengandung kata
- N : jumlah seluruh dokumen

2.3 Cosine Similarity

Cosine similarity merupakan metode yang digunakan untuk menghitung tingkat kemiripan antar vector teks.

Metode ini bekerja dengan mengukur sudut cosine antara dua vector. Semakin kecil sudut antar vector, maka semakin tinggi tingkat kemiripannya.

Pada proyek ini, cosine similarity digunakan untuk menghitung kemiripan antar course berdasarkan hasil embedding TF-IDF. (Christopher, 2008)

Rumus cosine similarity:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Nilai similarity berada pada rentang:

0 → Tidak Mirip

1 → Sangat Mirip

2.4 Content-Based Filtering

Content-based filtering merupakan metode recommendation system yang bekerja dengan menganalisis atribut atau fitur dari suatu item.

Pada proyek ini, recommendation system dibangun menggunakan fitur:

- Title,
- Description,
- Skills,
- Level course.

Sistem akan merekomendasikan course yang memiliki kemiripan konteks dengan query pengguna berdasarkan hasil embedding dan similarity score. (Arya Anggara & Ridho, 2024)

Metode ini dipilih karena mampu menghasilkan rekomendasi yang lebih personal dan relevan terhadap kebutuhan pengguna.

2.5 A/B Testing

A/B Testing merupakan metode evaluasi yang digunakan untuk membandingkan performa dua sistem atau metode berbeda. (Han et al., 2011)

Pada proyek ini, A/B Testing digunakan untuk membandingkan:

1. Embedding Recommendation
2. Keyword Matching

Evaluasi dilakukan menggunakan:

- Relevance score,
- Average score,
- Independent t-test.

Tujuan pengujian ini adalah untuk mengetahui apakah metode embedding memiliki performa yang lebih baik dibanding keyword matching sederhana.

BAB III

METODOLOGI PENELITIAN

3.1 Data Collection

Dataset yang digunakan pada penelitian ini merupakan dataset course Coursera yang berasal dari Kaggle dan diakses melalui platform Hugging Face Dataset Repository. (azrai99, 2024)

Dataset yang digunakan adalah:

Coursera Courses Dataset

Jumlah data awal: ±6645 course

Dataset memiliki beberapa fitur penting seperti:

- Title
- Description
- Skills
- Rating
- Level
- URL

Data tersebut digunakan sebagai sumber utama dalam pengembangan recommendation system berbasis konten.

3.2 Data Preprocessing

Tahap preprocessing dilakukan untuk membersihkan dan mempersiapkan data sebelum digunakan pada proses analisis dan embedding.

Tahapan preprocessing yang dilakukan meliputi:

a. Seleksi Fitur

Hanya fitur yang relevan dipilih, yaitu:

- Title
- Description
- Skills
- Rating
- Level
- Url

b. Missing Value Handling

Data yang memiliki nilai kosong pada kolom penting seperti:

- Description
- Skills
- Level

dihapus agar tidak mempengaruhi kualitas recommendation system.

c. Data Type Conversion

Beberapa kolom diubah ke tipe data yang sesuai:

- Text → String

- Rating → Float
- d. **Text Cleaning**
Kolom skills dinormalisasi dengan mengubah seluruh teks menjadi lowercase agar konsisten.
- e. **JSON Transformation**
Data skills diubah menjadi format dictionary/JSON dengan ID numerik agar lebih terstruktur.

Tahap preprocessing bertujuan meningkatkan kualitas data sehingga sistem rekomendasi dapat bekerja lebih optimal.

3.3 Exploratory Data Analysis (EDA)

EDA dilakukan untuk memahami karakteristik dataset sebelum membangun model recommendation system.

Analisis yang dilakukan meliputi:

- Distribusi level course,
- Distribusi rating,
- Panjang description,
- Jumlah skills,
- Top skills,
- Dan karakteristik teks lainnya.

Visualisasi dilakukan menggunakan:

- Histogram,
- Countplot,
- Barplot,
- Dan heatmap.

EDA membantu memahami pola data serta menentukan pendekatan terbaik dalam proses recommendation system.

3.4 Feature Engineering

Pada tahap ini dilakukan penggabungan beberapa fitur teks menjadi satu representasi informasi.

Fitur yang digabungkan:

- title
- description
- skills
- level

Gabungan fitur tersebut disimpan pada kolom: `combined_features`

Tujuan feature engineering adalah memberikan konteks informasi yang lebih lengkap kepada model embedding sehingga recommendation system dapat memahami hubungan antar course dengan lebih baik.

3.5 Embedding dan Recommendation System

Tahap berikutnya adalah membangun recommendation system menggunakan TF-IDF embedding dan cosine similarity.

a. TF-IDF Embedding

TF-IDF digunakan untuk mengubah teks menjadi vector numerik.

Fitur teks yang telah digabungkan akan direpresentasikan dalam bentuk vector sehingga dapat dihitung tingkat kemiripannya.

b. Cosine Similarity

Cosine similarity digunakan untuk menghitung similarity score antar course.

Semakin tinggi similarity score, maka semakin relevan course tersebut terhadap query pengguna.

c. Recommendation Function

Sistem menerima input query dari pengguna, kemudian:

1. Query diubah menjadi vector TF-IDF,
2. Similarity dihitung,
3. Recommendation diurutkan,
4. Top recommendation ditampilkan.

Metode ini memungkinkan sistem menghasilkan recommendation berbasis konteks, bukan hanya keyword literal.

3.6 Evaluasi Sistem

Evaluasi dilakukan menggunakan pendekatan A/B Testing untuk membandingkan:

- Embedding Recommendation
- Keyword Matching

Pengujian dilakukan menggunakan beberapa query seperti:

- machine learning
- data science
- artificial intelligence
- python

Metode evaluasi yang digunakan:

- average relevance score,
- similarity score,
- dan independent t-test.

Hasil evaluasi menunjukkan bahwa embedding recommendation memiliki performa lebih baik dibanding keyword matching sederhana.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Data Preprocessing

Tahap preprocessing berhasil membersihkan dataset sehingga data siap digunakan pada proses analisis dan recommendation system.

Beberapa proses yang dilakukan meliputi:

- Menghapus missing value,
- Menangani data kosong pada kolom skills,
- Mengubah tipe data,
- Normalisasi teks.

Setelah proses cleaning dilakukan:

- Jumlah data berubah dari 6.645 menjadi 4.354 course,
- Seluruh fitur utama berada dalam kondisi bersih,
- Dan data siap digunakan untuk proses embedding.

Hasil preprocessing juga menunjukkan bahwa:

- Tidak terdapat data duplikat,
- Tipe data sudah konsisten,
- Fitur teks telah dinormalisasi.

4.2 Hasil Exploratory Data Analysis (EDA)

EDA dilakukan untuk memahami karakteristik dataset course.

a. Distribusi Tingkat Kesulitan Course

Hasil visualisasi menunjukkan bahwa sebagian besar course berada pada:

- Beginner level,
- Dan intermediate level.

Sedangkan jumlah advanced level lebih sedikit.

Hal ini menunjukkan bahwa platform pembelajaran lebih banyak menyediakan materi untuk pengguna pemula hingga menengah.

b. Top Skills yang Dominan

Berdasarkan hasil analisis, skill yang paling sering muncul adalah:

- Data Analysis,
- Python Programming,
- Machine Learning,
- Data Visualization.

Hasil ini menunjukkan bahwa sebagian besar course berfokus pada bidang teknologi dan data science.

c. Analisis Description Course

Sebagian besar course memiliki description yang cukup panjang dan informatif. Hal ini penting karena description menjadi salah satu fitur utama dalam proses embedding dan semantic recommendation.

Description yang lebih lengkap membantu sistem memahami konteks course dengan lebih baik.

d. Analisis Rating Course

Mayoritas course memiliki rating yang relatif tinggi. Hal ini menunjukkan bahwa dataset berisi course dengan kualitas pembelajaran yang cukup baik berdasarkan penilaian pengguna.

Course dengan rating tinggi juga berpotensi menghasilkan recommendation yang lebih berkualitas.

4.3 Implementasi Recommendation System

Recommendation system dibangun menggunakan:

- TF-IDF embedding,
- Cosine similarity.

Tahapan recommendation system:

1. Menggabungkan fitur teks,
2. Mengubah teks menjadi vector TF-IDF,
3. Menghitung similarity score,
4. Menghasilkan top recommendation.

Sistem menerima input query pengguna seperti:

- Machine learning,
- Data science,
- Artificial intelligence,

kemudian menghasilkan recommendation course yang paling relevan.

4.4 Hasil Recommendation

Hasil recommendation menunjukkan bahwa sistem berhasil menghasilkan course yang relevan terhadap query pengguna.

Query “machine learning” menghasilkan recommendation course yang masih berkaitan dengan:

- AI,
- Deep learning,
- Data science,
- Neural network.

Nilai similarity score yang cukup tinggi menunjukkan bahwa embedding berhasil memahami hubungan semantik antar course.

4.5 Perbandingan Embedding dengan Keyword Matching

Sebagai pembandingan digunakan metode keyword matching sederhana.

Hasil analisis menunjukkan bahwa:

- Keyword Matching hanya bekerja berdasarkan kecocokan literal kata,
- Embedding mampu memahami konteks dan hubungan antar teks.

Embedding recommendation menghasilkan recommendation yang lebih fleksibel dan relevan dibanding keyword matching.

4.6 Hasil A/B Testing

A/B Testing dilakukan untuk membandingkan performa:

1. Embedding Recommendation
2. Keyword Matching

Berdasarkan hasil pengujian:

- Average Embedding Score = 0.56
- Average Keyword Matching Score = 0.23

Hasil independent t-test menunjukkan:

$$p\text{-value} = 0.00043 < 0.05$$

Karena p-value lebih kecil dari 0.05, maka terdapat perbedaan performa yang signifikan antara kedua metode.

Dengan demikian, metode embedding terbukti lebih efektif dibanding keyword matching sederhana.

4.7 Pembahasan Hasil

Berdasarkan seluruh hasil analisis dan evaluasi, recommendation system berbasis embedding mampu menghasilkan recommendation yang:

- Lebih relevan,
- Lebih kontekstual,
- Dan lebih adaptif terhadap kebutuhan pengguna.

TF-IDF embedding berhasil merepresentasikan hubungan antar course dalam bentuk vector numerik, sedangkan cosine similarity mampu mengukur tingkat kemiripan antar course secara efektif.

Selain itu, hasil evaluasi statistik juga memperkuat bahwa metode embedding memiliki performa yang lebih baik dibanding pendekatan sederhana berbasis keyword matching.

Dengan demikian, sistem Edu-Assist memiliki potensi untuk membantu pengguna menemukan course pembelajaran yang lebih sesuai dengan minat dan kebutuhan mereka.

BAB V

KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil analisis data, pembangunan recommendation system, serta evaluasi yang telah dilakukan, dapat disimpulkan bahwa proyek Edu-Assist berhasil mengembangkan sistem rekomendasi course berbasis content-based filtering menggunakan TF-IDF embedding dan cosine similarity.

Hasil exploratory data analysis (EDA) menunjukkan bahwa sebagian besar course pada dataset berada pada kategori teknologi dan data science dengan dominasi level beginner dan intermediate.

Recommendation system yang dikembangkan mampu menghasilkan rekomendasi course yang relevan terhadap query pengguna berdasarkan hubungan semantik antar course.

Berdasarkan hasil evaluasi:

- Average embedding score sebesar 0.56,
- Sedangkan keyword matching hanya sebesar 0.23.

Hasil independent t-test juga menunjukkan:

$$p\text{-value} = 0.00043 < 0.05$$

Hasil tersebut menunjukkan bahwa metode embedding memiliki performa yang lebih baik dan signifikan dibanding keyword matching sederhana.

Dengan demikian, sistem Edu-Assist mampu memberikan rekomendasi pembelajaran yang lebih relevan, personal, dan adaptif terhadap kebutuhan pengguna.

DAFTAR PUSTAKA

- azrai99. (2024). *Coursera Course Dataset*. <https://huggingface.co/datasets/azrai99/coursera-course-dataset>
- Christopher, M. (2008). *Introduction to Information Retrieval*.
- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining Third Edition*.
- Imanda, H. (n.d.). *Pengembangan Sistem Retrieval Augmented Generation (RAG) pada Aplikasi Chatbot Pendidikan untuk Menunjang Pembelajaran Siswa = Development of a Retrieval-Augmented Generation (RAG) System in an Educational Chatbot Application to Support Student Learning Handaneswari Pramudhyta Imanda, author*.
- Ricci, F., Rokach, L., & Shapira, B. (2011). Introduction to Recommender Systems Handbook. In *Recommender Systems Handbook* (pp. 1–35). Springer US. https://doi.org/10.1007/978-0-387-85820-3_1
- Salton, G., & Buckley, C. (1988). TERM-WEIGHTING APPROACHES IN AUTOMATIC TEXT RETRIEVAL. In *Information Processing & Management* (Vol. 24, Number 5).
- Arya Anggara, A., & Ridho, A. (2024). *Sistem Rekomendasi Pembelajaran dengan Menggunakan Metode Content-Based Filtering Berbasis Aplikasi Android*. 3(1), 11–19. <http://jurnal.utu.ac.id/JTI>